

WORKSHOP DE CIENCIA DE DATOS

INFORME DE PRÁCTICA

Análisis de salud mental en el sector tecnológico
con Power BI y KNN

Preparación, imputación y visualización inteligente
de la encuesta OSMI Mental Health in Tech

Estudiante	Alonzo Pinargote Roberth Alexander
Fecha de ejecución	29 de julio de 2026
Modalidad	Power BI Desktop
Materia	Inteligencia Artificial “A”
Docente	Oscar Gonzalez

Evidencias de preparación, modelado y resultados

1. Introducción

La encuesta Mental Health in Tech de OSMI reúne información sobre salud mental, condiciones laborales y acceso a recursos dentro del sector tecnológico. En esta práctica se aplicó un proceso basado en CRISP-ML(Q) para importar y depurar el conjunto de datos, normalizar variables, completar respuestas faltantes mediante el algoritmo KNN y construir un informe interactivo en Power BI con medidas DAX y visuales de inteligencia artificial.

2. Objetivos

2.1 Objetivo general

Desarrollar un informe analítico en Power BI que permita explorar los factores asociados con la búsqueda de tratamiento y la disponibilidad de recursos de salud mental en profesionales del sector tecnológico.

2.2 Objetivos específicos

- Importar y preparar el dataset Mental Health in Tech Survey mediante Power Query.
- Normalizar variables como edad y género, y conservar campos de auditoría del proceso.
- Aplicar un clasificador KNN para imputar valores faltantes en InterferenciaTrabajo.
- Crear medidas DAX y una columna calculada para resumir los principales indicadores.
- Construir un tablero, visuales de influenciadores clave y un árbol de descomposición.

3. Configuración empleada

Parámetro	Valor utilizado
Dataset	Mental Health in Tech Survey (OSMI, 2014)
Registros analizados	1.250 registros válidos
Herramientas	Power BI, Power Query, DAX y Python
Imputación	KNN de clasificación con $k = 5$
Resultado final	4 páginas interactivas de análisis

4. Desarrollo de la práctica

4.1 Estructura de campos y medidas DAX





Figura 1. Panel de datos con medidas y variables principales.

Se verificó que la tabla “Mental Health in Tech” contiene las medidas porcentuales de búsqueda de ayuda, historial familiar, interferencia imputada y tratamiento, además de variables como Edad, Anonimato, BeneficiosSaludMental y GeneroAgrupado. Esta estructura permite combinar indicadores calculados con los campos originales del estudio.

4.2 Variables de auditoría y métricas calculadas



InterferenciaFueImputada
InterferenciaTrabajo
InterferenciaTrabajoOriginal
MentalVsFisica
OpcionesCuidado
ProgramaBienestar
Supervisor
 Total Búsqueda Ayuda Sí
 Total en Tratamiento
 Total Encuestados
 Total Historial Familiar
 Total Interferencia Imputada
TrabajadorIndependiente
TrabajoRemoto
Tratamiento

Figura 2. Campos de imputación, totales y variables laborales.

El modelo conserva tres campos de auditoría: InterferenciaTrabajoOriginal, InterferenciaTrabajo e InterferenciaFueImputada. Estos campos permiten diferenciar los datos observados de los valores completados mediante KNN. También se crearon medidas para el total de encuestados, tratamiento, historial familiar, búsqueda de ayuda e interferencia imputada.

4.3 Tablero principal interactivo




Figura 3. Tablero principal de la encuesta OSMI.

El tablero integra segmentadores por género, trabajo remoto y cantidad de empleados, gráficos comparativos, una matriz y tarjetas de indicadores. En la captura se encuentran activos los filtros Male, TrabajoRemoto = Yes y CantidadEmpleados = 100-500; bajo este contexto se muestran 31 encuestados, 17 en tratamiento, 54,84 % de tratamiento, edad promedio de 32,97 años, 38,71 % con historial familiar y 25,81 % de interferencia imputada.

4.4 Influenciadores clave de tratamiento




Figura 4. Factores asociados con Tratamiento = Yes.

El visual de influenciadores clave analiza qué condiciones se asocian con una mayor probabilidad de haber buscado tratamiento. En los resultados observados, `HistorialFamiliar = Yes` incrementa la probabilidad promedio en 2,09 veces e `InterferenciaTrabajo = Sometimes` en 1,85 veces. El campo `InterferenciaFueImputada` permite separar los registros originales de los completados y reducir el riesgo de interpretar la imputación como evidencia directa.

4.5 Influenciadores clave de recursos de ayuda




Figura 5. Factores asociados con BusquedaAyuda = Don't know.

La segunda página analiza la incertidumbre sobre los recursos empresariales para buscar ayuda. ProgramaBienestar = Don't know aparece asociado con un incremento de 3,51 veces en la probabilidad de BusquedaAyuda = Don't know, mientras que BeneficiosSaludMental = Don't know presenta un incremento de 2,94 veces. Estos resultados evidencian una relación entre el desconocimiento de programas y la falta de claridad sobre las opciones de apoyo.

4.6 Árbol de descomposición del tratamiento




Figura 6. Descomposición interactiva del total en tratamiento.

El árbol parte de 631 personas en tratamiento y desglosa el resultado por género, trabajo independiente, anonimato, tamaño de empresa, programa de bienestar e interferencia laboral. La primera división registra 449 hombres, 169 mujeres y 13 personas agrupadas como Other. Esta visualización permite recorrer segmentos concretos y descubrir concentraciones sin asumir relaciones causales.

4.7 Dataset depurado y columnas de control

Table: Mental Health in Tech (1,250 rows) Column: Edad (44 distinct values)

Edad	Genero	TrabajadorIndependiente	HistorialFamiliar	Tratamiento	InterferenciaTrabajo	CantidadEmpleados	TrabajoRemoto	EmpresaTecnologica	BeneficiosSaludMental
41	Male	No	No	Yes	Never	More than 1000	No	No	Don't know
30	Male	No	No	Yes	Sometimes	26-100	No	Yes	Don't know
30	Male	No	Yes	Yes	Rarely	26-100	No	Yes	Yes
32	Male	No	No	No	Never	1-5	Yes	Yes	Don't know
32	Male	No	No	No	Never	100-500	No	Yes	Yes
28	Male	No	No	No	Never	More than 1000	No	Yes	Don't know
27	Male	No	No	No	Never	6-25	No	Yes	No
27	Male	No	Yes	Yes	Sometimes	More than 1000	No	Yes	Don't know
26	Male	No	Yes	No	Rarely	6-25	No	Yes	Yes
31	Male	No	No	No	Never	26-100	No	Yes	Don't know
24	Male	No	No	No	Never	26-100	No	Yes	Don't know
28	Male	No	No	No	Rarely	6-25	No	Yes	Don't know
36	Male	No	No	Yes	Sometimes	26-100	No	Yes	Yes
37	Male	No	Yes	Yes	Often	26-100	No	Yes	Yes
21	Male	No	No	Yes	Often	6-25	No	No	Don't know
34	Male	No	No	No	Sometimes	26-100	No	No	Yes
18	Male	No	No	Yes	Sometimes	6-25	No	Yes	Don't know
32	Male	No	No	No	Never	More than 1000	No	Yes	Yes
26	Male	No	No	No	Rarely	100-500	No	Yes	Yes
25	Male	No	No	No	Never	26-100	Yes	Yes	Don't know
29	Male	No	No	No	Never	More than 1000	No	No	Yes
23	Male	No	No	No	Never	More than 1000	No	No	Yes
34	Male	No	No	No	Sometimes	26-100	No	Yes	Don't know
28	Male	No	No	No	Never	6-25	No	Yes	Don't know
27	Male	No	Yes	Yes	Sometimes	100-500	No	Yes	Don't know
29	Male	No	No	Yes	Rarely	6-25	No	Yes	Yes
32	Male	No	No	No	Never	26-100	No	Yes	No

Figura 7. Vista de datos después de la preparación e imputación.

La vista de datos confirma la carga de 1.250 filas y la correcta tipificación de Edad como número entero. También se observan las variables renombradas al español y las columnas de control InterferenciaTrabajoOriginal e InterferenciaFueImputada, que permiten auditar qué respuestas fueron modificadas durante la imputación.

4.8 Modelo de datos en Power BI




Figura 8. Modelo de una tabla para el análisis OSMI.

El proyecto utiliza una estructura tabular única denominada “Mental Health in Tech”. Como todas las variables, medidas y columnas calculadas pertenecen al mismo conjunto de datos, no fue necesario crear relaciones adicionales. Este diseño resulta suficiente para el alcance del workshop y simplifica la navegación entre campos y visualizaciones.

5. Resultados obtenidos

- El dataset fue importado, depurado y consolidado en una tabla de 1.250 registros válidos.
- Se crearon medidas DAX para tratamiento, historial familiar, búsqueda de ayuda, edad e imputación.
- La imputación KNN conservó el valor original y una bandera de auditoría para cada registro modificado.
- El informe quedó organizado en cuatro páginas interactivas: tablero, dos análisis de influenciadores y árbol de descomposición.
- El análisis global registró 631 personas en tratamiento y permitió explorar los resultados mediante filtros y segmentaciones.

6. Concepto clave aprendido durante el Workshop

6.1 Aprendizaje principal

Power BI permite integrar preparación de datos, aprendizaje automático y analítica visual dentro de un mismo flujo. En esta práctica, Power Query organizó la información, Python y KNN completaron respuestas faltantes, DAX generó indicadores reutilizables y los visuales de inteligencia artificial facilitaron la identificación de asociaciones relevantes. El aprendizaje principal fue que la calidad y trazabilidad de los datos son tan importantes como el diseño final del dashboard.

7. Conclusiones

La práctica demostró que el conjunto OSMI puede convertirse en un informe analítico completo mediante una secuencia ordenada de preparación, imputación, modelado y visualización. La normalización de campos y la conservación de columnas de auditoría permitieron mantener la trazabilidad del proceso, mientras que las medidas DAX resumieron los principales indicadores de forma dinámica.

Los influenciadores clave y el árbol de descomposición facilitaron la exploración de factores relacionados con el tratamiento y con el conocimiento de recursos empresariales. Sin embargo, los resultados representan asociaciones dentro de una encuesta y no deben interpretarse como diagnósticos médicos ni como relaciones causales. El proyecto final ofrece una base reutilizable para futuros análisis de bienestar laboral y salud mental en entornos tecnológicos.