

WORKSHOP DE CIENCIA DE DATOS

INFORME DE PRÁCTICA

Auditoría de sesgos, ética y calidad
en Machine Learning

Evaluación de un clasificador de ingresos más allá de la accuracy
mediante métricas globales, análisis por grupos y cambio de umbral

Estudiante	Alonzo Pinargote Roberth Alexander
Fecha de ejecución	29 de julio de 2026
Modalidad	Google Colab
Materia	Inteligencia Artificial “A”
Docente	Oscar Gonzalez

Evidencias de ejecución, análisis y resultados

1. Introducción

La auditoría de modelos de Machine Learning exige revisar más que una métrica global. En esta práctica se utilizó el dataset Adult Census Income, disponible mediante OpenML, para entrenar y comparar modelos de clasificación orientados a predecir si el ingreso anual registrado supera los USD 50 000. El análisis se ejecutó en Google Colab y se enfocó en la calidad de los datos, el desbalance de clases, los tipos de error, las diferencias entre grupos y los riesgos éticos asociados con el uso del modelo.

2. Objetivos

2.1 Objetivo general

Ejecutar una auditoría técnica y ética de un modelo de clasificación, evaluando su rendimiento global, sus errores, sus diferencias entre grupos y las condiciones necesarias para un uso responsable.

2.2 Objetivos específicos

- Cargar y explorar el dataset Adult Census Income con 48 842 registros y 15 columnas.
- Identificar variables numéricas, categóricas, sensibles y valores faltantes.
- Construir una versión individual del modelo mediante una selección propia de variables.
- Comparar accuracy, precision, recall, F1-score y matriz de confusión.
- Auditar el desempeño por sexo, raza e intersecciones entre grupos.
- Evaluar el efecto de diferentes umbrales de decisión y documentar sus trade-offs.
- Emitir una recomendación basada en evidencias, consecuencias humanas y limitaciones.

3. Configuración empleada

Parámetro	Valor utilizado
Dataset	Adult Census Income - OpenML ID 1590
Registros	48 842
Variable objetivo	income: <=50K / >50K
Algoritmo	Regresión logística con pipeline de preparación
Variables del modelo participante	workclass, education-num, occupation, capital-gain, capital-loss, hours-per-week
Atributos sensibles directos	sex y race excluidos del entrenamiento individual
Umbral elegido para evaluación	0.40
Decisión final	Uso únicamente con condiciones y controles

4. Desarrollo de la práctica

4.1 Apertura del notebook en Google Colab




Figura 1. Copia individual del notebook abierta en Google Colab.

Se trabajó sobre una copia personal del notebook del taller. La primera sección planteó el caso de una organización que desea utilizar un modelo para predecir ingresos y solicitó asumir el rol de auditor antes de aprobar su uso.

4.2 Registro de criterios previos

Pregunta: ¿qué cinco cosas necesitarías saber antes de permitir su uso?

Una organización desea utilizar un modelo de Machine Learning para predecir si el ingreso anual de una persona supera los USD 50 000. Antes de aprobarlo, cada participante asumirá el rol de auditor y deberá evaluar su desempeño, sus errores, sus posibles sesgos y las condiciones bajo las cuales podría utilizarse.

Tu respuesta (2 minutos):

1. ...
2. ...
3. ...
4. ...
5. ...

Figura 2. Respuesta inicial sobre la información necesaria antes de aprobar el modelo.

Antes de ejecutar el código se registraron cinco aspectos esenciales: propósito del modelo, origen y población de los datos, métricas complementarias, resultados por grupos y consecuencias de los falsos positivos y falsos negativos.

4.3 Carga del dataset y vista inicial

```
adult = fetch_openml(data_id=1590, as_frame=True)
df_raw = adult.frame.copy()

# En OpenML la etiqueta se llama "class"; la renombramos para leerla mejor.
if "class" in df_raw.columns:
    df_raw = df_raw.rename(columns={"class": "income"})

print(f"Filas: {df_raw.shape[0]:,} | Columnas: {df_raw.shape[1]:,}")
display(df_raw.head())
```

Filas: 48,842 | Columnas: 15

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	income
0	25	Private	226802	11th	7	Never-married	Machine-op-inspct	Own-child	Black	Male	0	0	40	United-States	<=50K
1	38	Private	89814	HS-grad	9	Married-civ-spouse	Farming-fishing	Husband	White	Male	0	0	50	United-States	<=50K
2	28	Local-gov	336951	Assoc-acdm	12	Married-civ-spouse	Protective-serv	Husband	White	Male	0	0	40	United-States	>50K
3	44	Private	160323	Some-college	10	Married-civ-spouse	Machine-op-inspct	Husband	Black	Male	7688	0	40	United-States	>50K
4	18	NaN	103497	Some-college	10	Never-married	NaN	Own-child	White	Female	0	0	30	United-States	<=50K

Figura 3. Carga del dataset Adult Census Income desde OpenML.

La fuente fue cargada mediante `fetch_openml` con el identificador 1590. El conjunto contiene 48 842 filas y 15 columnas; la etiqueta `class` fue renombrada como `income` para facilitar la interpretación.

4.4 Detalle de los primeros registros

```
adult = fetch_openml(data_id=1590, as_frame=True)
df_raw = adult.frame.copy()

# En OpenML la etiqueta se llama "class"; la renombramos para leerla mejor.
if "class" in df_raw.columns:
    df_raw = df_raw.rename(columns={"class": "income"})

print(f"Filas: {df_raw.shape[0]}, | Columnas: {df_raw.shape[1]}")
display(df_raw.head())
```

Filas: 48,842 | Columnas: 15

	age	workclass	fnlwt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	income
0	25	Private	226802	11th	7	Never-married	Machine-op-inspct	Own-child	Black	Male	0	0	40	United-States	<=50K
1	38	Private	89814	HS-grad	9	Married-civ-spouse	Farming-fishing	Husband	White	Male	0	0	50	United-States	<=50K
2	28	Local-gov	336951	Assoc-acdm	12	Married-civ-spouse	Protective-serv	Husband	White	Male	0	0	40	United-States	>50K
3	44	Private	160323	Some-college	10	Married-civ-spouse	Machine-op-inspct	Husband	Black	Male	7688	0	40	United-States	>50K
4	18	NaN	103497	Some-college	10	Never-married	NaN	Own-child	White	Female	0	0	30	United-States	<=50K

Figura 4. Muestra de los primeros cinco registros del dataset.

La vista inicial permitió comprobar variables como edad, tipo de empleo, educación, ocupación, raza, sexo, ganancias de capital, horas de trabajo, país de origen e ingreso observado.

4.5 Diccionario mínimo de variables

Diccionario mínimo

- `age`, `education-num`, `hours-per-week`, `capital-gain/loss` : numéricas.
- `workclass`, `education`, `marital-status`, `occupation`, `relationship`, `native-country` : categóricas.
- `sex`, `race` : atributos sensibles disponibles en categorías históricas limitadas.
- `fnlwgt` : peso censal; no es una medición simple de la persona.
- `income` : etiqueta observada.

Que una columna esté disponible **no significa** que sea apropiada para cualquier uso.

Antes de ejecutar: hacer un inventario de columnas

Vocabulario: `dtype` es el tipo de dato; `NaN` representa ausencia; `nunique` cuenta valores distintos.

¿Qué hace? Resume para cada columna su tipo, cantidad de faltantes y cantidad de valores diferentes.

¿Qué no hace? No decide automáticamente qué columnas son buenas, sensibles o útiles.

¿Qué debes observar? Qué variables tienen faltantes y cuáles son numéricas o categóricas.

No necesitas memorizar el código. Ejecuta la celda con el botón ► y concentra tu atención en la pregunta que responde su resultado.

Figura 5. Diccionario mínimo y criterios para inventariar columnas.

El notebook diferenció variables numéricas, categóricas, sensibles y la etiqueta objetivo. También señaló que la disponibilidad de una columna no implica que sea apropiado utilizarla en cualquier contexto.

4.6 Inventario de tipos y valores faltantes





Figura 6. Código y salida inicial del inventario de columnas.

El inventario resumió el tipo de dato, la cantidad de valores faltantes y los valores únicos de cada columna. Los principales faltantes se ubicaron en occupation, workclass y native-country.

4.7 Resultado completo del inventario



	tipo	faltantes_detectados	valores_unicos
occupation	category	2809	14
workclass	category	2799	8
native-country	category	857	41
fnlwgt	int64	0	28523
education	category	0	16
education-num	int64	0	16
age	int64	0	74
marital-status	category	0	7
relationship	category	0	6
sex	category	0	2
race	category	0	5
capital-gain	int64	0	123
capital-loss	int64	0	99
hours-per-week	int64	0	96
income	category	0	2

Pasos siguientes: [Generar código con resumen_tipos](#) [New interactive sheet](#)

Figura 7. Tabla completa de tipos, faltantes y valores únicos.

Se identificaron 2 809 valores faltantes en occupation, 2 799 en workclass y 857 en native-country. Las variables sex, race e income contienen categorías históricas que requieren una lectura crítica.

4.8 Vista adicional del inventario de datos




Figura 8. Vista ampliada del inventario de columnas.

La captura adicional confirma la coexistencia de variables numéricas y categóricas y permite comprobar que el resto de campos no presentó valores faltantes detectados en esta etapa.

4.9 Normalización de marcadores de ausencia

```

df = df_raw.copy()
columnas_texto = df.select_dtypes(include=["object", "category", "string"]).columns

for columna in columnas_texto:
    serie = df[columna].astype("string").str.strip()
    serie = serie.mask(serie.eq("?"))
    df[columna] = serie.astype(object)
    df[columna] = df[columna].where(pd.notna(df[columna]), np.nan)

faltantes = df.isna().sum().sort_values(ascending=False)
print("Faltantes después de normalizar marcadores:")
display(faltantes[faltantes > 0].to_frame("n"))
print("Filas con atributos idénticos (no necesariamente personas duplicadas):",
      int(df.duplicated().sum()))

```

*** Faltantes después de normalizar marcadores:

	n
occupation	2809
workclass	2799
native-country	857

Filas con atributos idénticos (no necesariamente personas duplicadas): 52

Figura 9. Normalización de textos y marcadores de valores faltantes.

Se eliminaron espacios, se convirtieron marcadores como “?” en valores nulos y se verificó que permanecieran los mismos faltantes principales. También se detectaron 52 filas con atributos idénticos, sin asumir que correspondieran a personas duplicadas.

4.10 Medición del desbalance de clases




Figura 10. Conteo y proporción de la variable objetivo.

La clase <=50K contiene 37 155 registros, equivalentes al 76.07 %, mientras que la clase >50K contiene 11 687 registros, equivalentes al 23.93 %. Este desbalance explica por qué la accuracy puede resultar engañosa.

4.11 Visualización de la distribución de la etiqueta




Figura 11. Gráfico de distribución de las clases de ingreso.

El gráfico evidencia la diferencia de representación entre las dos clases. Un modelo que favorezca la clase mayoritaria podría obtener una accuracy aparentemente alta sin detectar correctamente los casos positivos.

4.12 Representación por grupo y efecto de eliminar faltantes




Figura 12. Comparación de la etiqueta por sex y simulación de dropna.

El conjunto contiene 16 192 registros Female y 32 650 Male. La proporción positiva fue de 10.9 % y 30.4 %, respectivamente. Eliminar todas las filas incompletas descartaría 3 620 registros y modificaría la composición de los grupos.

4.13 Selección individual de variables

5. Ronda preliminar: construye tu propia versión del modelo

Antes de conocer el modelo de referencia, selecciona las variables que consideres más adecuadas para predecir si el ingreso anual registrado supera USD 50 000.

Tu objetivo no es únicamente obtener la mayor accuracy. Considera también:

- simplicidad;
- facilidad de interpretación;
- calidad y disponibilidad;
- atributos sensibles;
- posibles proxies;
- consecuencias de los errores.

Todos utilizaremos el mismo dataset, la misma división, el mismo algoritmo, los mismos hiperparámetros y el mismo pipeline. **La única diferencia será la selección de variables.**

Variables disponibles

Variable	Descripción breve
age	Edad registrada
workclass	Tipo de empleo
education	Nivel educativo como categoría
education-num	Nivel educativo codificado numéricamente
marital-status	Estado civil registrado
occupation	Ocupación
relationship	Relación familiar registrada
race	Categoría racial histórica y sensible
sex	Categoría sexual histórica y sensible
capital-gain	Ganancia de capital registrada
capital-loss	Pérdida de capital registrada
hours-per-week	Horas de trabajo semanales
native-country	País de origen registrado

`income` es la etiqueta y no puede seleccionarse como entrada. `fnlwt` se excluye del ejercicio porque es un peso censal que requeriría un tratamiento especializado.

Antes de ejecutar: elegir variables

Vocabulario: Seleccionar variables significa decidir qué columnas recibirá el modelo. El código de participante identifica tu experimento sin depender de tu nombre.

Figura 13. Ronda preliminar para elegir variables del modelo participante.

Se seleccionaron seis variables: `workclass`, `education-num`, `occupation`, `capital-gain`, `capital-loss` y `hours-per-week`. No se incluyeron directamente `sex` ni `race`, buscando reducir el uso explícito de atributos sensibles.

4.14 Métricas y matriz de confusión del modelo participante




Figura 14. Rendimiento global, matriz de confusión y resultados por grupo.

El modelo participante obtuvo accuracy 0.818, precision 0.726, recall 0.387 y F1-score 0.505. La matriz registró 8 862 verdaderos negativos, 427 falsos positivos, 1 792 falsos negativos y 1 130 verdaderos positivos.

4.15 Resumen oficial del experimento individual

```

resumen_form_participante = {
    "Código del participante": código_participante.strip(),
    "Variables seleccionadas": ", ".join(variables_participante),
    "Número de variables": len(variables_participante),
    "Incluyó sex": "si" if "sex" in variables_participante else "no",
    "Incluyó race": "si" if "race" in variables_participante else "no",
    "Accuracy": round(metrics_participante["accuracy"], 4),
    "Precision": round(metrics_participante["precision"], 4),
    "Recall": round(metrics_participante["recall"], 4),
    "F1-score": round(metrics_participante["f1"], 4),
    "Verdaderos positivos": int(tp_part),
    "Falsos positivos": int(fp_part),
    "Falsos negativos": int(fn_part),
    "Diferencia de recall": round(brecha_recall_participante, 4),
    "Diferencia de FPR": round(brecha_fpr_participante, 4),
    "Grupo con menor recall": grupo_menor_recall_participante
}

for campo, valor in resumen_form_participante.items():
    print(f"{campo}: {valor}")

```

```

--- Código del participante: P001
Variables seleccionadas: workclass, education-num, occupation, capital-gain, capital-loss, hours-per-week
Número de variables: 6
Incluyó sex: No
Incluyó race: No
Accuracy: 0.8383
Precision: 0.7728
Recall: 0.3867
F1-score: 0.5846
Verdaderos positivos: 1130
Verdaderos negativos: 8862
Falsos positivos: 427
Falsos negativos: 1792
Diferencia de recall: 0.0135
Diferencia de FPR: 0.0155
Grupo con menor recall: female

```

Figura 15. Resumen generado para registrar el experimento.

La salida confirmó las seis variables seleccionadas, la exclusión de sex y race, las métricas exactas y las brechas por grupo. El grupo Female presentó el menor recall, con una diferencia de 0.0135 frente al grupo Male.

4.16 Comparación con modelos de referencia

Ejemplos con la referencia:

- Accuracy **0.852** significa 85.2 % de aciertos y **14.8 % de errores**.
- Precision **0.743** significa que aproximadamente **25.7 % de las predicciones positivas no coincidieron** con la etiqueta.
- Recall **0.585** significa que se detectó 58.5 % de los positivos y **se perdió 41.5 %**.
- F1 **0.654** resume un equilibrio intermedio; no es una nota de aprobación.
- ROC-AUC **0.904** indica buen ordenamiento relativo, pero no garantiza un umbral adecuado, calibración o equidad.

En una demostración educativa podemos describir un valor como alto, medio o bajo **respecto a otra versión**. Para aprobar un uso real se necesitan requisitos definidos antes de entrenar. En decisiones de alto impacto, incluso un porcentaje de error aparentemente pequeño puede afectar a muchas personas.

```
globales = pd.DataFrame({
    "Línea base": resumen_global(y_test, pred_base),
    "Con sex": resumen_global(y_test, pred_con_sex, proba_con_sex),
    "Sin sex": resumen_global(y_test, pred_sin_sex, proba_sin_sex)
}).T
display(globales.round(3))
```

	accuracy	balanced_accuracy	precision	recall	f1	tasa_seleccion	roc_auc
Línea base	0.761	0.500	0.000	0.000	0.000	0.000	NaN
Con sex	0.852	0.762	0.740	0.589	0.656	0.190	0.904
Sin sex	0.852	0.761	0.743	0.585	0.654	0.188	0.904

Figura 16. Métricas globales de la línea base y los modelos con y sin sex.

La línea base alcanzó 0.761 de accuracy pero recall 0, porque no detectó ningún positivo. Los modelos de referencia con y sin sex obtuvieron aproximadamente 0.852 de accuracy y un recall cercano a 0.59.

4.17 Matriz de confusión del modelo sin sex

¿Qué no hace? No establece cuál error es moralmente peor; eso depende de la decisión que active el modelo.

¿Qué debes observar? Dónde están los falsos positivos y los falsos negativos y qué significarían en un escenario concreto.

No necesitas memorizar el código. Ejecuta la celda con el botón ▶ y concentra tu atención en la pregunta que responde su resultado.

```

matriz = confusion_matrix(y_test, pred_sin_sex, labels=[0, 1])
fig, ax = plt.subplots(figsize=(5, 4))
sns.heatmap(
    matriz, annot=True, fmt="d", cmap="Blues", cbar=False, ax=ax,
    xticklabels=["Pred <=50K", "Pred >50K"],
    yticklabels=["Real <=50K", "Real >50K"]
)
ax.set_title("Matriz de confusión · modelo sin sex")
ax.set_xlabel("Predicción")
ax.set_ylabel("Etiqueta observada")
plt.show()

tn, fp, fn, tp = matriz.ravel()
print(f"{'TN': int(tn), 'FP': int(fp), 'FN': int(fn), 'TP': int(tp)}")

```




Figura 17. Matriz de confusión del modelo de referencia sin sex.

El modelo sin sex registró 8 699 verdaderos negativos, 590 falsos positivos, 1 214 falsos negativos y 1 708 verdaderos positivos. Mejoró la detección de positivos respecto al modelo participante, aunque aumentó los falsos positivos.

4.18 Auditoría del modelo de referencia por sex

```

tabla_grupo = metricas_por_grupo(y_test, pred_sin_sex, A_test)
display(tabla_grupo.round(3))

```

	soporte	positivos_reales	accuracy	precision	recall	fpr	fnr	tasa_seleccion
grupo								
Female	4024	453	0.924	0.739	0.506	0.023	0.494	0.077
Male	8187	2469	0.817	0.744	0.599	0.089	0.401	0.243

Figura 18. Métricas por grupo del modelo sin sex.

El recall fue 0.506 para Female y 0.599 para Male. La tasa de selección fue 0.077 y 0.243, respectivamente. Quitar la variable sex del entrenamiento no eliminó las diferencias entre grupos.

4.19 Cálculo de brechas entre grupos

Antes de ejecutar: resumir diferencias con una brecha

Vocabulario: Una brecha es el valor máximo menos el mínimo. 0.094 equivale a 9.4 puntos porcentuales.

¿Qué hace? Resume la distancia entre grupos para recall y FPR.

¿Qué no hace? No muestra la dirección, no considera incertidumbre y una brecha cero no garantiza un buen sistema.

¿Qué debes observar? Después del número vuelve siempre a la tabla para identificar qué grupo tiene cada valor.

No necesitas memorizar el código. Ejecuta la celda con el botón ▶ y concentra tu atención en la pregunta que responde su resultado.

```
# Reto: reemplaza None con máximo menos mínimo.  
brecha_recall = (0.599 - 0.506)  
brecha_fpr = (0.089 - 0.023)  
print("Brecha recall:", brecha_recall)  
print("Brecha FPR:", brecha_fpr)
```

```
*** Brecha recall: 0.09299999999999997  
Brecha FPR: 0.066
```

Figura 19. Brechas de recall y FPR.

La brecha de recall fue aproximadamente 0.093 y la brecha de FPR fue 0.066. Estas cifras deben leerse junto con la tabla por grupos, ya que una brecha no muestra por sí sola la dirección ni las causas de la diferencia.

4.20 Comparación de decisiones de diseño




Figura 20. Comparación del modelo participante, línea base y referencias.

El modelo participante presentó menores brechas, pero un recall considerablemente inferior. Los modelos de referencia mejoraron el rendimiento global, aunque mostraron mayores diferencias de recall, FPR y tasa de selección.

4.21 Auditoría por raza e intersecciones




Figura 21. Métricas por race y por la intersección sex x race.

El análisis mostró variaciones relevantes entre categorías raciales e intersecciones. Female x Black presentó recall 0.353 y tasa de selección 0.026. Los grupos pequeños se interpretaron con cautela por su bajo soporte.

4.22 Preparación del análisis de umbrales

```
[22]
✓ 0 s
files_umbral = []
for umbral in [0.30, 0.40, 0.50, 0.60, 0.70]:
    pred_umbral = (proba_sin_sex >= umbral).astype(int)
    global_umbral = resumen_global(y_test, pred_umbral)
    grupo_umbral = metricas_por_grupo(y_test, pred_umbral, A_test)
    filas_umbral.append({
        "umbral": umbral,
        "global_umbral": global_umbral,
        "brecha_recall": (
            grupo_umbral["recall"].max() -
            grupo_umbral["recall"].min()
        ),
        "brecha_fpr": (
            grupo_umbral["fpr"].max() -
            grupo_umbral["fpr"].min()
        )
    })

resultados_umbral = pd.DataFrame(filas_umbral).set_index("umbral")
display(resultados_umbral.round(3))

resultados_umbral[
    ["precision", "recall", "brecha_recall", "brecha_fpr"]
].plot(marker="o", figsize=(9, 5))
plt.title("Trade-offs al cambiar el umbral")
plt.ylabel("Valor")
plt.ylim(0, 1)
plt.show()
```

Figura 22. Código para evaluar umbrales entre 0.30 y 0.70.

Se utilizaron las mismas probabilidades del modelo y se modificó únicamente el umbral de clasificación. El propósito fue observar el trade-off entre precisión, recall, tasa de selección y brechas.

4.23 Resultados de los diferentes umbrales




Figura 23. Tabla y gráfico de trade-offs al cambiar el umbral.

Bajar el umbral aumentó el recall, pero también elevó los falsos positivos y las brechas. El umbral 0.40 obtuvo accuracy 0.850, precision 0.687, recall 0.685 y F1-score 0.686.

4.24 Evaluación detallada del umbral 0.40




Figura 24. Métricas globales y por grupo con umbral 0.40.

Con el umbral elegido, el recall alcanzó 0.589 para Female y 0.702 para Male. Aunque se redujeron los falsos negativos, permanecieron diferencias importantes en recall, FPR y tasa de selección.

4.25 Preparación de la comparación final

```
def resumen_para_comparar(y_true, y_pred, grupos):
    global_m = resumen_global(y_true, y_pred)
    tn_c, fp_c, fn_c, tp_c = confusion_matrix(
        y_true, y_pred, labels=[0, 1]
    ).ravel()
    grupos_m = metricas_por_grupo(y_true, y_pred, grupos)
    return {
        "Número de variables": np.nan,
        "Accuracy": global_m["accuracy"],
        "Precision": global_m["precision"],
        "Recall": global_m["recall"],
        "F1-score": global_m["f1"],
        "Falsos positivos": int(fp_c),
        "Falsos negativos": int(fn_c),
        "Brecha de recall": (
            grupos_m["recall"].max() - grupos_m["recall"].min()
        ),
        "Brecha de FPR": (
            grupos_m["fpr"].max() - grupos_m["fpr"].min()
        )
    }

participante_comp = resumen_para_comparar(
    y_test, predicciones_participante, A_test
)
participante_comp["Número de variables"] = len(variables_participante)

referencia_comp = resumen_para_comparar(
    y_test, pred_sin_sex, A_test
)
referencia_comp["Número de variables"] = X_test_sin.shape[1]

modificado_comp = resumen_para_comparar(
    y_test, pred_elegida, A_test
)
modificado_comp["Número de variables"] = X_test_sin.shape[1]

comparacion_tres_modelos = pd.DataFrame({
    "Tu modelo": participante_comp,
    "Referencia (umbral 0.50)": referencia_comp,
    f"Modificado (umbral {umbral_elegido:.2f})": modificado_comp
})
display(comparacion_tres_modelos.round(3))
```

Figura 25. Función para resumir y comparar tres versiones del modelo.

La comparación final integró número de variables, métricas globales, falsos positivos, falsos negativos y brechas. De esta manera se evitó seleccionar un ganador únicamente por accuracy.

4.26 Comparación final de los tres modelos

	Tu modelo	Referencia (umbral 0.50)	Modificado (umbral 0.40)
Número de variables	6.000	12.000	12.000
Accuracy	0.818	0.852	0.850
Precision	0.726	0.743	0.687
Recall	0.387	0.585	0.685
F1-score	0.505	0.654	0.686
Falsos positivos	427.000	590.000	910.000
Falsos negativos	1792.000	1214.000	921.000
Brecha de recall	0.014	0.094	0.113
Brecha de FPR	0.016	0.066	0.100

Figura 26. Modelo participante, referencia 0.50 y modelo modificado 0.40.

El modelo modificado redujo los falsos negativos a 921 y mejoró el recall a 0.685, pero aumentó los falsos positivos a 910 y las brechas. La referencia 0.50 ofreció un equilibrio intermedio entre rendimiento y diferencias por grupo.

4.27 Interpretación de coeficientes y posibles proxies




Figura 27. Asociaciones positivas y negativas aprendidas por la regresión logística.

Entre las asociaciones positivas destacaron capital-gain, education-num y ocupaciones ejecutivas. También aparecieron estado civil y país de origen, lo cual obliga a considerar proxies, desigualdades históricas y la diferencia entre asociación y causalidad.

5. Resultados obtenidos

- El dataset analizado contiene 48 842 registros y presenta un desbalance de 76.07 % para $\leq 50K$ frente a 23.93 % para $> 50K$.
- El modelo participante empleó seis variables y obtuvo accuracy 0.8183, precision 0.7258, recall 0.3867 y F1-score 0.5046.
- La principal debilidad del modelo participante fueron 1 792 falsos negativos, pese a presentar brechas pequeñas entre Female y Male.
- El modelo de referencia sin sex mejoró el recall a 0.585, pero mantuvo diferencias por grupo y una tasa de selección mucho mayor para Male.
- El umbral 0.40 elevó el recall a 0.685 y redujo los falsos negativos a 921, a costa de aumentar los falsos positivos a 910 y las brechas entre grupos.
- El análisis por race e intersecciones reveló resultados especialmente desfavorables en algunos grupos, aunque las categorías con bajo soporte requieren más datos antes de extraer conclusiones definitivas.
- La revisión de coeficientes mostró que eliminar sex no impide que otras variables actúen como proxies o reproduzcan patrones históricos.

6. Concepto clave aprendido durante el Workshop

6.1 Aprendizaje principal

Una accuracy alta no garantiza que un modelo sea justo, útil o seguro. La evaluación responsable debe integrar matriz de confusión, precision, recall, F1-score, desempeño por grupos, consecuencias de los errores, calidad y representatividad de los datos, posibles proxies y mecanismos de supervisión y reparación.

7. Decisión de auditoría

Se recomienda utilizar el modelo únicamente con condiciones. El umbral 0.40 mejora la detección de positivos y reduce falsos negativos, pero mantiene brechas relevantes y aumenta los falsos positivos. Antes de cualquier implementación deberían actualizarse los datos, validar el sistema con población local, revisar variables sensibles e indirectas, establecer supervisión humana, auditorías periódicas, documentación de limitaciones y un mecanismo de apelación. No debería utilizarse para tomar de forma automática decisiones de alto impacto.

8. Conclusiones

La práctica demostró que optimizar una sola métrica puede ocultar problemas importantes. El modelo participante fue más simple y presentó menores brechas, pero tuvo un recall insuficiente. Los modelos de referencia detectaron más positivos, aunque mostraron diferencias mayores entre grupos. El cambio de umbral confirmó que mejorar recall implica aceptar más falsos positivos y, en este caso, mayores brechas.

La auditoría también evidenció que retirar una variable sensible no elimina automáticamente el sesgo, ya que otras columnas pueden conservar información correlacionada. Por esta razón, la aprobación de un modelo debe depender del contexto, la población, las consecuencias de sus errores y la existencia de controles humanos y organizacionales, no únicamente de su accuracy.